

Proyecto de Machine Learning: "¿Feliz o Triste?" versión rápida

Clasificación de emociones faciales con Teachable Machine

1. Introducción

La inteligencia artificial ha avanzado de forma acelerada en los últimos años, permitiendo a máquinas reconocer patrones complejos como emociones humanas a partir de imágenes, sonidos o texto. En este proyecto se propone el uso de **Teachable Machine**, una herramienta web creada por Google, para crear y entrenar un modelo que pueda clasificar rostros humanos según dos emociones básicas: **felicidad** y **tristeza**.

2. Objetivo general

Desarrollar y entrenar un modelo de aprendizaje automático basado en visión por computador que clasifique expresiones faciales como **felices** o **tristes**, utilizando la plataforma Teachable Machine, y analizar cómo la cantidad de datos y su diversidad influye en la **precisión del modelo**.

3. Objetivos específicos

- Recopilar un conjunto diverso de imágenes representando las emociones “feliz” y “triste”.
- Entrenar un modelo de clasificación de imágenes en Teachable Machine.
- Evaluar el modelo con diferentes imágenes en tiempo real o previamente capturadas.
- Analizar el impacto de aumentar la cantidad y diversidad de datos sobre el rendimiento del modelo.
- Reflexionar sobre las implicaciones éticas del uso de IA en reconocimiento facial y análisis emocional.

4. Herramientas y tecnologías utilizadas

Herramienta	Uso
Teachable Machine	Plataforma para crear y entrenar el modelo ML
Webcam / cámara	Captura de imágenes para entrenamiento
Navegador web	Interfaz para trabajar con Teachable Machine
PC o laptop	Dispositivo de procesamiento y entrenamiento
Exportación (opcional)	Uso del modelo en páginas web o aplicaciones



5. Metodología

◆ Fase 1: Preparación del proyecto

1. **Acceso a la herramienta:**
 - Ingresar a <https://teachablemachine.withgoogle.com>
 - Seleccionar: **"Image Project"** > **"Standard Image Model"**
2. **Definición de clases:**
 - Clase 1: **Feliz**
 - Clase 2: **Triste**
3. **Configuración del entorno:**
 - Iluminación adecuada
 - Fondo neutro o variado (para probar robustez)
 - Acceso a cámara o imágenes preexistentes

◆ Fase 2: Recolección de datos

- Capturar múltiples imágenes en distintas condiciones:
 - Diferentes personas (si es posible)
 - Variación en luz (natural / artificial)
 - Expresiones realistas, no exageradas
 - Ángulos distintos (frontal, lateral)



Recomendación mínima:

- 30 imágenes por clase para comenzar
- Aumentar a 100 imágenes por clase para mejorar el modelo

◆ Fase 3: Entrenamiento del modelo

- Hacer clic en **"Entrenar Modelo"**
- Elegir entrenamiento básico o avanzado (con ajustes personalizados)
- Esperar la finalización del proceso de entrenamiento (segundos o minutos)

◆ Fase 4: Evaluación y prueba

- Utilizar la cámara en tiempo real para probar el modelo.
- Subir imágenes nuevas para comprobar la capacidad de generalización.
- Analizar errores o confusiones.

Ejemplo de resultados:

Imagen	Clasificación esperada	Clasificación del modelo	¿Correcta?
Rostro sonriente	Feliz	Feliz	✓
Rostro serio	Triste	Triste	✓/✗
Rostro parcial	Feliz	Triste	✗



6. Evaluación de precisión y mejora del modelo

- ¿Qué pasa si agregas más imágenes?
 - El modelo mejora si tiene más ejemplos y más variabilidad.
 - Reduce **overfitting** (cuando solo reconoce ciertos rostros o condiciones).
- ¿Qué pasa si usas a otras personas?
 - Mide qué tan generalizable es el modelo.
- ¿Influye la iluminación?
 - La luz puede afectar los resultados si el modelo no está entrenado con variedad de condiciones.



7. Conceptos clave involucrados

Concepto	Descripción
Machine Learning (ML)	Disciplina que permite a sistemas aprender automáticamente de datos.
Modelo de clasificación	Tipo de modelo ML que asigna una clase a una entrada (imagen).
Entrenamiento supervisado	Aprendizaje a partir de datos etiquetados.
Dataset	Conjunto de datos utilizados para entrenar el modelo.
Precisión	Porcentaje de predicciones correctas sobre el total de predicciones.
Overfitting	Cuando un modelo aprende demasiado los datos de entrenamiento y falla con nuevos.
Generalización	Capacidad del modelo para funcionar bien con datos nuevos o desconocidos.



8. Posibles extensiones del proyecto

- Agregar más emociones: **Enojado, Sorprendido, Neutral**
- Clasificación de **sonidos** o **movimientos** usando Teachable Machine

- Exportar el modelo para usarlo en una **página web con JavaScript**
- Conectar el modelo a una **Raspberry Pi o Arduino con cámara**
- Evaluar el impacto de sesgos: ¿Detecta mejor hombres que mujeres? ¿Adultos que niños?

9. Consideraciones éticas

El reconocimiento facial plantea preguntas éticas importantes:

- ¿Es correcto que una máquina clasifique nuestras emociones?
- ¿Qué pasa si se usa sin consentimiento?
- ¿Podrían usarse estos modelos para vigilancia?
- ¿Cómo evitamos sesgos raciales, de género o edad en los modelos?

 Este proyecto puede incluir una **discusión ética final** para reflexionar sobre el uso responsable de la IA.



10. Conclusiones

- Teachable Machine permite experimentar de forma intuitiva con Machine Learning.
- Es posible entrenar modelos con alta precisión, incluso sin saber programar.
- La cantidad y calidad de datos **impactan directamente** en el rendimiento del modelo.
- Este tipo de modelos tienen aplicaciones reales en salud, educación, videojuegos y tecnología asistiva.
- Es fundamental tener en cuenta los aspectos **éticos** y **sociales** al desarrollar IA con capacidades de análisis emocional.

Resumen del Proyecto

Este proyecto utiliza machine learning para crear un modelo que clasifique imágenes de rostros humanos en dos categorías emocionales: "feliz" o "triste". El objetivo es explorar cómo el aumento de datos de entrenamiento afecta la precisión del modelo.

Componentes del Proyecto

1. Recopilación de Datos

- **Conjunto inicial:** 500 imágenes etiquetadas (250 felices, 250 tristes)

- **Fuentes potenciales:**
 - Conjuntos públicos como FER-2013, CK+
 - Imágenes de stock con licencia
 - Captura propia con consentimiento informado

2. Preprocesamiento

- **Técnicas:**
 - Detección y alineación de rostros (usando Haar cascades o MTCNN)
 - Normalización de tamaño (48x48 píxeles)
 - Conversión a escala de grises
 - Equalización de histograma para mejorar contraste

3. Arquitectura del Modelo

- **Enfoque:** Transfer Learning con MobileNetV2
- **Capas personalizadas:**
 - Capa Flatten
 - Dense (128 unidades, ReLU)
 - Dropout (0.5)
 - Dense (1 unidad, sigmoide)

4. Entrenamiento

- **División de datos:**
 - 70% entrenamiento
 - 15% validación
 - 15% prueba
- **Hiperparámetros:**
 - Tasa de aprendizaje: 0.0001
 - Batch size: 32
 - Épocas: 50 (con early stopping)

5. Implementación Web

- **Frontend:**
 - Interfaz para subir imágenes
 - Visualización de resultados
 - Opción para contribuir con imágenes etiquetadas
- **Backend:**

- API Flask/FastAPI
- Procesamiento en tiempo real
- Almacenamiento seguro de nuevas imágenes

6. Experimentación con Volumen de Datos

- Fase 1: Entrenar con 500 imágenes
- Fase 2: Aumentar a 1,000 imágenes (añadiendo contribuciones)
- Fase 3: Evaluar con 2,000 imágenes
- Métricas a comparar:
 - Precisión
 - Recall
 - F1-score
 - Pérdida de validación

Análisis Esperado

Se anticipa que:

1. El modelo base (500 imágenes) logrará ~75% de precisión
2. Con 1,000 imágenes, la precisión aumentará a ~82%
3. Con 2,000 imágenes, se estabilizará alrededor del 85-88%

Consideraciones Éticas

- Privacidad: Todas las imágenes deben ser anónimas
- Consentimiento: Para imágenes nuevas, obtener permiso explícito
- Sesgo: Garantizar diversidad en edad, género y etnia

Implementación con Table Machine

1. Configurar el proyecto en Table Machine
2. Cargar conjuntos de datos etiquetados
3. Diseñar el pipeline de preprocesamiento
4. Seleccionar arquitectura de modelo
5. Programar ciclo de entrenamiento-evaluación
6. Implementar interfaz de usuario web
7. Configurar mecanismo para añadir datos incrementales

Evaluación Continua

- Matriz de confusión después de cada fase
- Curvas de aprendizaje
- Análisis de ejemplos mal clasificados

Este proyecto demostrará cómo el volumen de datos afecta el rendimiento en un problema de visión por computadora aplicado al reconocimiento emocional, proporcionando insights valiosos sobre la relación datos-rendimiento en ML.



RÚBRICA DE EVALUACIÓN

Criterio	Excelente (4 pts)	Bueno (3 pts)	Aceptable (2 pts)	Insuficiente (1 pt)
Definición del problema	Explica claramente el objetivo del proyecto y la relevancia del uso de IA en la clasificación emocional.	Explica el objetivo, pero con algunos detalles poco desarrollados.	Hay confusión en el planteamiento del objetivo.	No define claramente el problema ni la meta del proyecto.
Organización del dataset (imágenes)	Recolectó más de 50 imágenes por clase, variadas y bien etiquetadas.	Recolectó entre 30 y 49 imágenes por clase.	Solo recolectó entre 15 y 29 imágenes por clase.	Menos de 15 imágenes por clase o con mala organización.
Entrenamiento del modelo	Entrenó correctamente el modelo, con análisis de tiempos y parámetros de entrenamiento.	Entrenó correctamente, pero sin análisis detallado.	Entrenó, pero con errores o sin repetir el proceso.	No logró entrenar un modelo funcional.
Evaluación y pruebas del modelo	Probó el modelo con datos externos, en vivo y analizó los errores.	Probó el modelo con algunos ejemplos nuevos.	Pruebas limitadas, solo con datos entrenados.	No hay evidencia de pruebas.
Análisis de resultados y mejoras propuestas	Analiza los resultados con profundidad, propone mejoras	Analiza algunos resultados y menciona	Mención básica de resultados sin análisis real.	No hay análisis de resultados.

Criterio	Excelente (4 pts)	Bueno (3 pts)	Aceptable (2 pts)	Insuficiente (1 pt)
	lógicas y reflexiona sobre el rendimiento del modelo.	mejoras superficiales.		
Aplicaciones reales del modelo	Expone al menos 3 posibles usos reales del modelo en la vida cotidiana o industria.	Menciona 1 o 2 posibles aplicaciones.	Mención muy superficial o sin relación práctica.	No identifica ninguna aplicación del modelo.
Uso ético y reflexivo de la IA	Discute a profundidad los dilemas éticos del uso del reconocimiento facial con IA.	Menciona algunos temas éticos con ejemplos.	Reconoce el tema, pero no profundiza.	No incluye ningún análisis ético.
Presentación del proyecto (oral o escrita)	Muy clara, estructurada, con recursos visuales, lenguaje técnico correcto y evidencia de comprensión.	Clara y comprensible, aunque con limitaciones en recursos o vocabulario técnico.	Presentación poco estructurada o muy básica.	Presentación confusa o incompleta.
Evidencia entregada	Entrega modelo entrenado, video de prueba, documento explicativo y presentación.	Entrega modelo y documento explicativo.	Solo entrega el modelo o evidencia mínima.	No entrega evidencia válida.

 **Puntaje total máximo: 36 puntos**

Rangos de calificación sugeridos

Puntaje Nivel de desempeño

32–36 Excelente

28–31 Bueno

20–27 Aceptable

< 20 Necesita mejorar



Estrategia de entrega y evidencias del proyecto



Productos entregados por el estudiante

1. **Modelo entrenado**
 - Exportado como archivo .zip (si aplica) o compartido como link desde Teachable Machine.
 - **Nombre sugerido:** Modelo_Feliz_Triste_NombreAlumno
2. **Video demostración (opcional pero recomendado)**
 - Grabación mostrando al modelo en acción.
 - Mínimo: demostrar 3 pruebas en vivo.
 - Puede ser grabado con celular o software como OBS.
 - **Duración sugerida:** 2–3 minutos.
 - **Formato:** .mp4 o YouTube con enlace.
3. **Documento explicativo (Word o PDF)**
 - Contenido sugerido:
 - Introducción al proyecto
 - Objetivo
 - Metodología
 - Capturas del proceso
 - Análisis de resultados
 - Propuestas de mejora
 - Reflexión ética
4. **Presentación (PowerPoint, Canva o Google Slides)**
 - Resumen visual del proyecto para exposición de 5–10 minutos.
 - Mínimo 6 diapositivas (portada, objetivos, metodología, resultados, ética, conclusión)
5. **Formulario de entrega (opcional para el docente)**
 - Google Form o Moodle para subir:
 - Link del modelo
 - Link del video (si aplica)
 - Archivos adjuntos